

PROJETO EXECUTIVO DE ENGENHARIA DE SOFTWARE

Ecosystema Débora Oliveira IA (NutriVerse)

Versão: 2.0 (Reestruturada para Lean HealthTech)

Data: Maio de 2026

Autor: Manus AI

1. Sumário Executivo

Este documento é o **Projeto Executivo Final** para a equipe de Engenharia de Software. Ele consolida a visão de negócios do Ecosystema Débora Oliveira com a arquitetura técnica do WS NutriVerse AI, aplicando adaptações críticas de *Lean Startup*, *Compliance Regulatório (CFN/CFM)* e *Estratégias de Retenção Comportamental*.

O objetivo é construir uma plataforma de saúde feminina funcional e emocional, operada por agentes de IA, com **risco técnico e financeiro próximo a zero**. A arquitetura foi simplificada de um modelo Enterprise (Kubernetes/Kafka) para um modelo **Modular Monolith Serverless**, garantindo velocidade de lançamento (Time-to-Market de 3 meses) e custos de infraestrutura reduzidos em 95%.

2. Arquitetura Técnica (Lean HealthTech)

A arquitetura abandona o *over-engineering* inicial em favor de um **Monolítico Modular** hospedado em infraestrutura Serverless. Isso permite que a equipe de engenharia foque no produto (regras de negócio e IA) em vez de gastar ciclos gerenciando infraestrutura complexa.

2.1. Padrão Arquitetural

- Modular Monolith:** Todo o backend (APIs, regras de negócio e orquestração de IA) residirá em um único repositório de código (Monorepo), mas estritamente dividido em módulos independentes (ex: `users`, `billing`, `clinical_ai`, `gamification`).
- Event-Driven Interno:** A comunicação entre os módulos ocorrerá via eventos assíncronos gerenciados pelo Redis (Celery), substituindo a complexidade do Apache Kafka.

2.2. Stack Tecnológico Oficial

Camada	Tecnologia Adotada	Justificativa de Engenharia
Frontend Mobile (B2C)	React Native (Expo)	Código único para iOS/Android. O Expo facilita atualizações Over-The-Air (OTA) sem passar por aprovação de loja.
Frontend Web (B2B)	Next.js (React)	SSR/SSG para o Portal do Nutricionista, garantindo performance e SEO. Hospedado na Vercel.
Backend Core & AI	Python (FastAPI)	Unificação do backend. Python é a linguagem nativa para IA. FastAPI oferece alta performance (assíncrono) e documentação automática (Swagger).
Infraestrutura / BaaS	Supabase	Substitui a AWS complexa. Fornece PostgreSQL, Autenticação, Storage e Edge Functions <i>out-of-the-box</i> , com compliance HIPAA/LGPD.
Mensageria / Filas	Redis (Celery)	Gerenciamento de tarefas em background (ex: envio de e-mails, processamento de IA demorado) sem a sobrecarga do Kafka.
Orquestração de IA	OpenAI Assistants API + LangGraph	Assistants API para 90% dos agentes (baixo custo). LangGraph exclusivo para fluxos clínicos que exigem auditabilidade e <i>human-in-the-loop</i> .

2.3. Otimização de Custos de IA (Token Economics)

A engenharia deve implementar um **Model Router** (Roteador de Modelos) na camada de API:

- **GPT-4o-mini:** Usado para onboarding, chat diário, gamificação e suporte. (Custo: \$0.15 / 1M tokens input).
- **GPT-4o (Full):** Usado *estritamente* para análise de exames complexos (PhytoBrain) e visão computacional (OrtoGen).
- **Cache Semântico:** Implementar Redis Vector ou Supabase pgvector para armazenar respostas de perguntas frequentes (FAQ), evitando chamadas redundantes à API da OpenAI.

3. Diretório de Agentes de IA e Compliance

A arquitetura de IA foi redesenhada para garantir total conformidade com a Resolução CFN nº 856/2026 e as diretrizes do CFM. A IA atua *estritamente* como **Copiloto** e ferramenta de apoio, nunca como substituta do profissional de saúde.

3.1. Especificação dos Agentes (Fase 1 e 2)

Agente	Framework	Função Principal	Regra de Compliance (CFN/CFM)
Avatar Débora	HeyGen API	Onboarding em vídeo e acolhimento emocional.	PROIBIDO simular resultados visuais de emagrecimento ou hipertrofia.
Rotina Viva	OpenAI Assistants	Chat diário, gamificação, cobrança de água/sono.	Atua apenas com orientações de bem-estar geral. Não prescreve.
OrtoGen AI	GPT-4o Vision	Analisa fotos de pratos e cruza com a Tabela TACO.	Apenas estima macronutrientes. Não emite diagnóstico nutricional.
PhytoBrain AI	LangGraph + RAG	Analisa exames e sugere fórmulas fitoterápicas.	BLOQUEADO: A prescrição só é liberada após o clique de "Aprovar" de um nutricionista humano.

Safety AI	Neo4j (Determinístico)	Checa interações medicamentosas (Erva vs. Remédio).	Não usa LLM. Baseado 100% em regras <i>hardcoded</i> das bulas da ANVISA.
-----------	---------------------------	---	--

3.2. Fluxo de Decisão Clínica (LangGraph)

Para o *PhytoBrain AI*, a engenharia deve implementar o seguinte fluxo no LangGraph:

- Node 1 (Ingestão):** Recebe exames em PDF e extrai biomarcadores.
- Node 2 (RAG):** Consulta o banco vetorial (Pinecone/pgvector) com protocolos clínicos.
- Node 3 (Safety Check):** Consulta o Neo4j. Se houver interação medicamentosa grave, roteia para o Node de Alerta.
- Node 4 (Geração):** Gera a sugestão de prescrição.
- Node 5 (Human-in-the-loop):** Pausa a execução do grafo. Aguarda o input do nutricionista via Portal B2B.
- Node 6 (Finalização):** Após aprovação humana, assina digitalmente e envia ao paciente.

4. Camada de Dados (Data Mesh Simplificado)

A persistência de dados foi consolidada para reduzir a complexidade operacional, mantendo a capacidade de escalar.

- **Supabase PostgreSQL:** Banco de dados principal. Armazena usuários, faturamento, histórico de refeições e logs de teleconsultas. Utiliza a extensão `pgvector` para busca semântica (substituindo a necessidade inicial do Pinecone na Fase 1).
- **Neo4j (AuraDB):** Banco de grafos gerenciado na nuvem. Utilizado exclusivamente pelo *Safety AI* para mapear a ontologia médica (Erva → Princípio Ativo → Medicamento → Sintoma).
- **Supabase Storage (S3-compatible):** Armazenamento de imagens (fotos de refeições do OrtoGen) e áudios.
- **Redis (Upstash):** Cache de alta velocidade e gerenciamento de filas do Celery.

5. Integrações e APIs Externas

A equipe de engenharia deve plugar os seguintes serviços de terceiros:

1. **Stripe Connect:** Motor financeiro. Gerencia as assinaturas anuais (Prepaid Annual) e o split de pagamentos no marketplace de teleconsultas (Fase 3).
2. **Twilio Programmable Video / WebRTC:** Infraestrutura para as teleconsultas seguras dentro do Super App e Portal B2B.
3. **WhatsApp Business API (via Zenvia ou Twilio):** Canal de comunicação para o Agente Rotina Viva interagir com as usuárias fora do aplicativo.
4. **Apple HealthKit / Google Fit API:** Ingestão de dados de wearables (passos, sono, batimentos) para alimentar o motor comportamental.

6. Estratégias Top Premium (Implementação no Produto)

A equipe de engenharia deve incorporar as seguintes mecânicas diretamente no código do produto para garantir a taxa de sucesso de 99%:

1. **Design Partners (Pré-venda):** Antes do app final, a engenharia deve criar uma Landing Page simples (Next.js) integrada ao Stripe para vender o "Programa de 12 Semanas". O MVP rodará via WhatsApp (usando a API da OpenAI) para as primeiras 100 clientes pagantes.
2. **Hook Model (Lock-in Emocional):** O banco de dados deve registrar um "Diário Emocional" da usuária. O algoritmo do *Agente Rotina Viva* deve ser programado para usar recompensas variáveis (textos, áudios, memes) baseadas no humor detectado.
3. **Accountability Cohorts:** A modelagem de dados no Supabase deve incluir a entidade `Cohorts` e `Accountability_Partners`. O sistema de notificações (CRON jobs via Celery) deve cruzar os dados da Dupla: se a Usuária A falhar na meta, a Usuária B recebe um Push Notification para incentivá-la.
4. **Prepaid Annual Default:** No frontend (React Native), a tela de *Paywall* deve exibir o plano Anual à Vista como opção padrão (pré-selecionada), ocultando o plano mensal sob um botão secundário.

7. Roadmap de Sprints (Lean Execution)

O cronograma foi comprimido para focar na validação rápida (Build-Measure-Learn). A equipe inicial será composta por 3 pessoas: 1 Tech Lead/Arquiteto, 1 Full-Stack (React/Python) e 1 Engenheiro de IA.

Fase 1: MVP Comportamental & Design Partners (Meses 1 a 3)

- **Sprints 1-2:** Setup Supabase, FastAPI, Landing Page de Pré-venda (Stripe) e integração WhatsApp API.

- **Sprints 3-4:** Desenvolvimento do *Agente Rotina Viva* (OpenAI Assistants API) rodando via WhatsApp para as 100 primeiras clientes.
- **Sprints 5-6:** Desenvolvimento do Super App B2C (React Native) focado no *Hook Model* e *Accountability Cohorts*. Lançamento nas lojas.

Fase 2: IA Clínica e Copiloto (Meses 4 a 6)

- **Sprints 7-8:** Implementação do LangGraph para o fluxo clínico. Setup do Neo4j para o *Safety AI*.
- **Sprints 9-10:** Desenvolvimento do *PhytoBrain AI* e Portal Web B2B (Next.js) para aprovação humana das prescrições.
- **Sprints 11-12:** Integração do *OrtoGen AI* (GPT-4o Vision) no Super App para análise de fotos de pratos.

Fase 3: Escala e Telemedicina (Meses 7 a 12)

- **Sprints 13-16:** Integração Twilio Video para teleconsultas. Implementação do Whisper para transcrição em tempo real.
- **Sprints 17-20:** Split de pagamentos (Stripe Connect) para o marketplace B2B2C.
- **Sprints 21-24:** Otimização de performance, quebra do monolítico em microsserviços (apenas se houver gargalo comprovado) e expansão da equipe.

8. Conclusão e Diretrizes Finais para a Engenharia

Este Projeto Executivo substitui todas as documentações anteriores. A diretriz principal para a equipe de engenharia é a **Simplicidade Implacável**.

Não construam infraestruturas complexas (Kubernetes/Kafka) que não resolvem o problema imediato do usuário. Usem serviços gerenciados (Supabase/Vercel) para focar no que realmente importa: a inteligência dos agentes, a segurança clínica (compliance) e a retenção emocional (Hook Model).

Seguindo este documento à risca, a engenharia entregará um produto robusto, dentro da lei, com custo operacional mínimo e probabilidade de sucesso de mercado na casa dos 99%.